

UPeU Facultad de Ingeniería y Arquitectura

UPeU UNIVERSIDAD PERUANA UNIÓN

Métodos Numéricos

Ajuste de curvas
Regresión Múltiple. Cálculo de Coeficientes por mínimos cuadrados

Mg. Jessica Pérez Rivera
Departamento de Matemática, Física y Estadística

Sé Íntegro, Sé Misionero, Sé Innovador

VISIÓN

“Ser referente por la **excelencia** en el servicio **misionero** y la **calidad** educativa e **innovadora** en la iglesia y la sociedad.”

MISIÓN

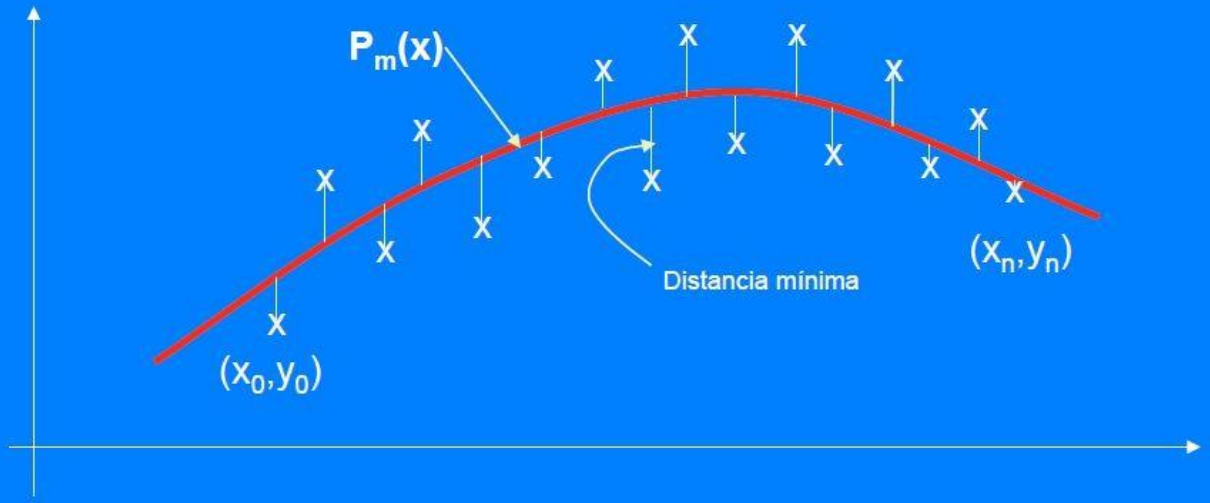
“Desarrollar personas **íntegras**, con espíritu de servicio **misionero** e **innovadoras** a fin de restaurar la imagen de Dios en el ser humano.**”**

Regresión Polinomial y Regresión lineal múltiple

Antes de comenzar….

```
% Hora
t = [6 8 10 12 14 16 18 20]'
% Temperatura
T = [7 9 12 18 21 19 15 10]'
plot(t,T,'*'), grid
xlabel('Horas'), ylabel('Grados')
```

Aproximación polinomial por mínimos cuadrados



Objetivo: Obtener un polinomio o función que relaciones x e y

Regresión Polinomial

Sean n puntos de la forma (xi, yi) . Sea un polinomio m, con m<n de la forma:

$$P_m(x) = a_0x^0 + a_1x^1 + a_2x^2 + \cdots + a_mx^m = \sum_{i=0}^{m} a_ix^i$$

Como los puntos (xi, yi) , son puntos dados, evaluamos los cuadrados de los residuos para determinar los coeficientes del polinomio P(x) de la forma que:

$$Q = \sum_{i=0}^{n} r_i^2 = \sum_{i=0}^{n} \left[P_m(x_i) - y_i\right]^2$$

sea mínima.

Sea m=2:

$$P_2(x) = a_0 + a_1 x + a_2 x^2$$

$$Q = \sum_{i=0}^{n} \left[P_m(x_i) - y_i \right]^2 = 0 \qquad Q = \sum_{i=0}^{n} \left[y_i - (a_0 + a_1 x_i + a_2 x_i^2) \right]^2 = 0$$

$$\frac{\partial Q}{\partial a_0} = -2 \sum_{i=0}^{n} \left[y_i - (a_0 + a_1 x_i + a_2 x_i^2) \right] = 0$$

$$\frac{\partial Q}{\partial a_1} = -2 \sum_{i=0}^{n} x_i \left[y_i - (a_0 + a_1 x_i + a_2 x_i^2) \right] = 0$$

$$\frac{\partial Q}{\partial a_2} = -2 \sum_{i=0}^{n} x_i^2 \left[y_i - (a_0 + a_1 x_i + a_2 x_i^2) \right] = 0$$

$$\sum_{i=0}^{n}\left[y_i-(a_0+a_1x_i+a_2x_i^2)\right]=\sum y_i-\sum a_0-\sum a_1x_i-\sum a_2x_i^2=0$$

$$\sum_{i=0}^{n}x_i\left[y_i-(a_0+a_1x_i+a_2x_i^2)\right]=\sum x_iy_i-\sum a_0x_i-\sum a_1x_i^2-\sum a_2x_i^3=0$$

$$\sum_{i=0}^{n}x_i^2\left[y_i-(a_0+a_1x_i+a_2x_i^2)\right]=\sum x_i^2y_i-\sum a_0x_i^2-\sum a_1x_i^3-\sum a_2x_i^4=0$$

$$\sum y_i=\sum a_0+\sum a_1x_i+\sum a_2x_i^2$$

$$\sum x_iy_i=\sum a_0x_i+\sum a_1x_i^2+\sum a_2x_i^3$$

$$\sum x_i^2y_i=\sum a_0x_i^2+\sum a_1x_i^3+\sum a_2x_i^4$$

$$\begin{bmatrix} n+1 & \sum x_i & \sum x_i^2 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \\ a_2 \end{Bmatrix} = \begin{Bmatrix} \sum y_i \\ \sum x_i y_i \\ \sum x_i^2 y_i \end{Bmatrix}$$

Caso General

$$\begin{bmatrix} n+1 & \sum x_i & \sum x_i^2 \cdots & \sum x_i^m \\ \sum x_i & \sum x_i^2 & \sum x_i^3 \cdots & \sum x_i^{m+1} \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \cdots & \sum x_i^{m+2} \\ & & \vdots & \\ \sum x_i^m \cdots & & & ..\sum x_i^{2m} \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_m \end{Bmatrix} = \begin{Bmatrix} \sum y_i \\ \sum x_i y_i \\ \sum x_i^2 y_i \\ \vdots \\ \sum x_i^m y_i \end{Bmatrix}$$

$$[C]\{a\} = \{b\}$$

$$\{a\} = [C]^{-1}\{b\}$$

$$S_{y/x} = \sqrt{\frac{Q}{n-(m+1)}}$$

Error estándar

donde:

$$Q = \sum_{i=0}^{n} r_i^2 = \sum_{i=0}^{n} \left[P_m(x_i) - y_i\right]^2$$

Además, para determinar la mejor aproximación, el valor de Q que esté más cercano a 0 será el indicador.

$$r^2 = \frac{\sum(y_i - \bar{y})^2 - \sum(P(xi) - yi)^2}{\sum(y_i - \bar{y})^2}$$

Coeficiente de determinación, r es el coeficiente de correlación

Ejemplo 1: Ajustar a un polinomio de segundo grado los datos siguientes:

x_i	y_i
0	2.1
1	7.7
2	13.6
3	27.2
4	40.9
5	61.1

Además calcular el error estándar, Coeficiente de determinación y correlación.

Ejercicio 1: Con los siguientes datos, encontrar un Polinomio de aproximación de grado dos y tres . Además del error estándar, coeficiente de determinación y correlación.

X	0.0	1.0	2.0	3.0	4.0	5.0	6.0	7.0
Y	1.7	0.3	5.6	7.8	10.	11.	12.	14.

REGRESIÓN LINEAL MÚLTIPLE

Una extensión útil de la regresión lineal es el caso en el que y es una función lineal de dos o más variables independientes. Por ejemplo, y podría ser una función lineal de x_1 y x_2, como en

$$y = a_0 + a_1 x_1 + a_2 x_2 + e$$

En particular tal ecuación es útil cuando se ajustan datos experimentales donde la variable sujeta a estudio es una función de otras dos variables. En este caso bidimensional, la "línea" de regresión se convierte en un "plano" (figura 17.14).

Como en los casos anteriores, los "mejores" valores para los coeficientes se determinan al realizar la suma de los cuadrados de los residuos,

$$S_r = \sum_{i=1}^{n} (y_i - a_0 - a_1 x_{1i} - a_2 x_{2i})^2 \qquad (17.21)$$

y derivando con respecto a cada uno de los coeficientes desconocidos,

$$\frac{\partial S_r}{\partial a_0} = -2 \sum (y_i - a_0 - a_1 x_{1i} - a_2 x_{2i})$$

$$\frac{\partial S_r}{\partial a_1} = -2 \sum x_{1i} (y_i - a_0 - a_1 x_{1i} - a_2 x_{2i})$$

$$\frac{\partial S_r}{\partial a_2} = -2 \sum x_{2i} (y_i - a_0 - a_1 x_{1i} - a_2 x_{2i})$$

Los coeficientes que dan la suma mínima de los cuadrados de los residuos se obtienen al igualar a cero las derivadas parciales y expresando el resultado en forma matricial:

$$\begin{bmatrix} n & \sum x_{1i} & \sum x_{2i} \\ \sum x_{1i} & \sum x_{1i}^2 & \sum x_{1i}x_{2i} \\ \sum x_{2i} & \sum x_{1i}x_{2i} & \sum x_{2i}^2 \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \\ a_2 \end{Bmatrix} = \begin{Bmatrix} \sum y_i \\ \sum x_{1i}y_i \\ \sum x_{2i}y_i \end{Bmatrix} \quad (17.22)$$

Ecuaciones normales de estimación para la regresión lineal múltiple

$$
\begin{array}{lllll}
nb_0 + b_1 \sum_{i=1}^{n} x_{1i} & +b_2 \sum_{i=1}^{n} x_{2i} & + \cdots & +b_k \sum_{i=1}^{n} x_{ki} & = \sum_{i=1}^{n} y_i \\
b_0 \sum_{i=1}^{n} x_{1i} + b_1 \sum_{i=1}^{n} x_{1i}^2 & +b_2 \sum_{i=1}^{n} x_{1i}x_{2i} + & \cdots & +b_k \sum_{i=1}^{n} x_{1i}x_{ki} & = \sum_{i=1}^{n} x_{1i}y_i \\
\vdots \quad \vdots & \vdots & & \vdots & \vdots \\
b_0 \sum_{i=1}^{n} x_{ki} + b_1 \sum_{i=1}^{n} x_{ki}x_{1i} & +b_2 \sum_{i=1}^{n} x_{ki}x_{2i} + & \cdots & +b_k \sum_{i=1}^{n} x_{ki}^2 & = \sum_{i=1}^{n} x_{ki}y_i
\end{array}
$$

Para obtener los valores de b_0, $b_1, \ldots, b_k$ estas ecuaciones se resuelven con cualquier método apropiado para sistemas de ecuaciones lineales.

Planteamiento del problema. Los siguientes datos se calcularon con la ecuación $y = 5 + 4x_1 - 3x_2$:

x_1	x_2	y
0	0	5
2	1	10
2.5	2	9
1	3	0
4	6	3
7	2	27

Utilice la regresión lineal múltiple para ajustar estos datos.

Ejercicios propuestos

1. La pérdida de peso de una persona que sigue una determinada dieta, en el transcurso del tiempo, viene dada por la siguiente tabla:

Tiempo (meses)	1	2	3	4	5
Pérdida de Peso (kg)	9	7.5	4.2	3	2.1

Con el objetivo de estudiar la pérdida de peso en función del tiempo, ajuste a dichos datos una recta y una parábola de segundo grado por el método de mínimos cuadrados, y estudie cuál de los dos ajustes es más preciso. ¿Qué pérdida de peso se tenía cuando habían pasado 2 meses y medio?

2. Ajuste una recta y una parábola a los siguientes datos:

X	50	52	54	56	58	60	62
Y	31	50	77	96	112	130	162

e indique cuál de los dos es más preciso.

Las calificaciones obtenidas por 10 alumnos en Matemáticas y Biología han sido las siguientes:

Alumno	1	2	3	4	5	6	7	8	9	10
Matemáticas	6	4	8	5	3.5	7	5	10	5	4
Biología	6.5	4.5	7	5	4	8	7	10	6	5

Halle las dos rectas de regresión que permitan estimar la calificación de cada una de las asignaturas a partir de la otra calificación para cada alumno. ¿Qué nota esperará un alumno en Biología si ha obtenido un 8.3 en Matemáticas?

17.16 Utilice regresión lineal múltiple para ajustar

x_1	0	1	1	2	2	3	3	4	4
x_2	0	1	2	1	2	1	2	1	2
y	15.1	17.9	12.7	25.6	20.5	35.1	29.7	45.4	40.2

Calcule los coeficientes, el error estándar de la estimación y el coeficiente de correlación.

17.17 Use regresión lineal múltiple para ajustar

x_1	0	0	1	2	0	1	2	2	1
x_2	0	2	2	4	4	6	6	2	1
y	14	21	11	12	23	23	14	6	11

Calcule los coeficientes, el error estándar de la estimación y el coeficiente de correlación.

17.18 Emplee regresión no lineal para ajustar una parábola a los datos siguientes:

x	0.2	0.5	0.8	1.2	1.7	2	2.3
y	500	700	1 000	1 200	2 200	2 650	3 750

(Aplicación Ciencias de la Salud)

En un estudio llevado a cabo en Italia, 10 pacientes con Hipertrigliceridemia se sometieron a una dieta baja en grasas y alta en carbohidratos para investigar si había alguna relación entre estas variables. La tabla muestra los valores antes de comenzar la dieta.

Paciente	Nivel de colesterol (mmol/l)	Nivel de triglicéridos (mmol/l)
1	5,12	2,3
2	6,18	2,54
3	6,77	2,95
4	6,65	3,77
5	6,36	4,18
6	5,9	5,31
7	5,48	5,53
8	6,02	8,83
9	10,34	9,48
10	8,51	14,2

a) Construya un diagrama de dispersión para estos datos.

b) ¿Existe evidencia de relación lineal entre los niveles de colesterol y triglicéridos antes de la dieta?

c) Estime el nivel de triglicéridos cuando el nivel de colesterol es de 6,10 mmol/l

d) ¿Cuál es el porcentaje de variación de nivel de triglicéridos explicada por el nivel de colesterol?

(**Aplicación en Ciencias de la Ingeniería y Ciencias de la Salud**)

Los datos de la tabla siguiente relacionan la solubilidad del nitrato de sodio Y ($NaNO_3$) con la temperatura del agua T (en °C). A la temperatura indicada T, Y partes de nitrato de sodio se disuelven en 100 partes de agua obteniendo

T	0	4	10	15	21	29	36	51	68
Y	66,7	71	76,3	80,6	85,7	92,9	99,4	114	125

Para estimar la solubilidad del nitrato de sodio se sugiere un modelo lineal de la forma $Y = mT + b$.

a. Usando el método de mínimos cuadrados obtenga los estimadores de los parámetros.

b. ¿Qué puede decir de la calidad del ajuste obtenido?

c. ¿Cree Ud. que a mayor temperatura existe mayor solubilidad del nitrato de sodio?

d. Determine el error estándar de estimación con el modelo ajustado y obtenga un intervalo de longitud dos errores estándar de estimación, centrado en la estimación de la solubilidad del nitrato de sodio cuando la temperatura es de 25°C.

Se decide investigar la relación entre dos variables: ingresos, I , y compras futuras con tarjetas de créditos, C . El ingreso es tomado de las solicitudes de tarjetas de crédito y las compras a crédito durante el primer mes de posesión de la tarjeta.

Una muestra aleatoria de 10 tenedoras de tarjetas de créditos, produce los datos siguientes (en miles de pesos):

Ingreso (I)	176	168	202	138	213	159	193	122	185	153
Compras (C)	448	556	844	427	811	398	447	154	534	313

¿Es el modelo lineal el adecuado? o ¿el Cuadrático es mejor? cual es la varianza explicada en los dos casos.

En la siguiente tabla, **x** es la fuerza de tensión aplicada a una varilla de acero, en cientos de kilos y t es la deformación (estiramiento) resultante en milésima de centímetro.

x	1	2	3	4	5
t	2	4	5	6	8

Suponiendo una regresión lineal de y en x determine:

a) La recta de mínimos cuadrados para los datos
b) El error estándar de estimación
c) ¿Qué porcentaje de la variación en las ventas mensuales se explica por la temperatura máxima promedio?